



# Classificação de Imagens Histológicas de Glomérulos Renais com Podocitopatia

Aluno: George Oliveira Barros  
george.barros@ifgoiano.edu.br

# Sumário


- Introdução
- Revisão de literatura
- Metodologia
- Resultados e discussão
- Conclusões e trabalhos futuros
- Referências

# Introdução

- **Histopatologia Digital**

- Histologia: estudo da anatomia microscópica de tecidos de organismos [1].
- Histopatologia: análise microscópica de seções histológicas com o objetivo da diferenciação entre tecidos biológicos saudáveis e doentes [2].

*Análise de seções de tecido biológico através de sistemas computacionais.*




# Introdução

- O que é uma imagem histológica?
  1. Biópsia
  2. Corte de seção de tecido
  3. Aplicação de corantes
  4. Observação ampliada por microscópio
  5. Aquisição da imagem


**Padrão ouro para diagnóstico médico de uma série de patologias!**



# Introdução



**Fig 1.** Ilustração das estruturas internas de um glomérulo




**Fig 2.** Imagem digital de glomérulo renal saudável

# Introdução


## Objetivo do trabalho:

Classificação de imagens de glomérulos renais como imagens:  
**com podocitopatia** ou **sem podocitopatia**.

a




b




**Fig 3.** Estruturas internas de um glomérulo



# Introdução



**Fig 4.** Sem lesão



**Fig 5.** Com lesão

# Revisão de literatura

## ❑ **Trabalhos similares:**

- ❑ Zeng et al. 2020: Segmentação de glomérulos e células internas [1].
- ❑ Chagas et al. 2019: Classificação de glomérulos com hiper celularidade, lesão mesangial e esclerótica.
- ❑ Ginley et al. 2020: Detecção de glomérulos.
- ❑ Pinaki et al. 2019: Lesão de glomérulos relacionadas a diabetes e hipertensão.


**Não há nenhum trabalho com foco nas lesões podocitárias.**



# Revisão de literatura

## ❑ Resnets

- ❑ Adição de blocos residuais
- ❑ Sendo  $x$  o resultado de uma camada, ao utilizar um bloco residual, o resultado se dá por  $y = x + f(x)$  (Kaiming He et al., 2015).




Fonte: *Residual block* (Kaiming He et al., 2015)

# Revisão de literatura

## ❑ Densenet

- ❑ Cada camada recebe informações de todas as camadas anteriores e não apenas a antecessora (Gao Huang et al., 2016).




# Revisão de literatura

## ❑ Data augmentation

- ❑ Ampliar o conjunto de dados por meio de operações nas imagens. Rotação, flip, ruído, entre outras. (Wong et al., 2016).

## ❑ Transfer learning:

- ❑ Transferência de aprendizado é a reutilização dos pesos de um modelo pré-treinado em um novo problema (Zhu et al., 2020).
- ❑ Técnica aplicada para treinar dataset menores, já que uma rede para conseguir uma generalização adequada em geral necessita de muitos dados.




# Metodologia


1. Dataset e Data augmentation
2. Arquiteturas utilizadas
3. Transfer learning
4. Avaliação dos modelos

# Metodologia

1. Dataset e Data augmentation: 376 imagens (176 com lesão), 70/30 (treino/teste).



Exemplos de imagens do dataset



Alguns resultado de  
*data augmentation*

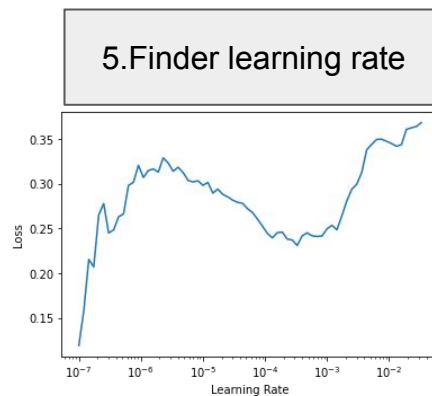

# Metodologia

## 1. Arquitetura utilizadas

- a. Resnet34
- b. Resnet50
- c. Resnet101
- d. Densenet121
- e. Densenet201

# Metodologia


## 1. Transfer learning



1. Carregar arquitetura pré-treinada com Imagenet



2. Finder learning rate



3. Ajuste de pesos da última camada com 5 épocas



4. Descongelamento das demais camadas





# Resultados e Discussão

- Resultados mais confiáveis com validação cruzada
- Natureza das imagens do Imagenet bem distinta do dataset utilizado
- Uso hiperparâmetros automáticos
- Apesar do data augmentation, dataset muito pequeno

Modelo	Acc.(%)	Prec.(%)	Recc.(%)	F1-score(%)	Pesos iniciais	Épocas
Resnet34	0,86	0,79	0,94	0,86	Imagenet	15
Resnet50	0,89	0,84	0,89	0,86	Imagenet	13
<b>Resnet101</b>	<b>0,93</b>	<b>0,89</b>	<b>0,94</b>	<b>0,92</b>	<b>Imagenet</b>	<b>7</b>
Densenet121	0,87	0,82	0,86	0,84	Imagenet	14
Densenet201	0,92	0,91	0,89	0,90	Imagenet	14

# Conclusões

- Resultados indicam que as CNNs podem ter bom desempenho para classificar lesão podocitária

## Trabalhos futuros

- ❑ Melhoria do dataset
- ❑ Testes com redes treinados do zero
- ❑ Implementação de validação cruzada
- ❑ Transfer learning com imagens mais parecidas
- ❑ Fine tuning dos hiperparâmetros
- ❑ Classificação dos tipos de lesões
- ❑ Segmentação e classificação dos podócitos lesionados

# Referências

- Zeng, C., Nan, Y., Xu, F., Lei, Q., Li, F., Chen, T., . . . Liu, Z. (2020). Identification of glomerular lesions and intrinsic glomerular cell types in kidney diseases via deep learning. <https://doi.org/10.1002/path.5491>
- Belsare, A. D.; Mushrif, M. M. Histopathological image analysis using image processing techniques: an overview. *Signal & image processing: an international journal (SIPIJ)* vol.3. 2012.
- Ginley, B. G., Emmons, T., Lutnick, B., Urban, C. F., Segal, B. H., & Sarder, P. (2017). Computational detection and quantification of human and mouse neutrophil extracellular traps in flow cytometry and confocal microscopy. *Scientific Reports*, 7(1), 1–11. <https://doi.org/10.1038/s41598-017-18099-y>
- Gao Huang, Zhuang Liu, Laurens van der Maaten, Kilian Q. Weinberger. Densely Connected Convolutional Networks (CVPR 2017). ArXiv:1608.06993, 2016.
- Kaiming He et al., Deep Residual Learning for Image Recognition (Microsoft Research). arXiv:1512.03385v1 [cs.CV] 10 Dec 2015.
- Sebastien C. Wong et al., Understanding data augmentation for classification: when to warp?. arXiv:1609.08764v2, 2016.
- Zhuangdi Zhu, Kaixiang Lin, Jiayu Zhou. Transfer Learning in Deep Reinforcement Learning: A Survey. arXiv:2009.07888, 2020.